

INFORME TÉCNICO: SISTEMA INTEGRAL DE MACHINE LEARNING PARA LA PREVENCIÓN DE LA DESERCIÓN Y ANÁLISIS DE RENDIMIENTO ESTUDIANTIL

Autor:

Martín Papic Vargas.

Profesor:

Giocrisrai Godoy Bonillo.

Fecha de entrega:

22 de Mayo del 2026

INFORME TÉCNICO: SISTEMA INTEGRAL DE MACHINE LEARNING PARA LA PREVENCIÓN DE LA DESERCIÓN Y ANÁLISIS DE RENDIMIENTO ESTUDIANTIL.....	1
1. RESUMEN EJECUTIVO.....	4
2. INTRODUCCIÓN Y PLANTEAMIENTO DEL PROBLEMA.....	5
2.1 Contexto de la Problemática.....	5
2.2 Formulación del Problema Analítico.....	5
2.3 Objetivos Generales y Específicos.....	6
3. MARCO TEÓRICO Y ESTADO DEL ARTE.....	7
3.1 Aprendizaje Supervisado en EDM.....	7
3.2 El Rol del Clustering Estudiantil.....	7
3.3 Innovación: Aprendizaje por Refuerzo en Educación.....	7
4. METODOLOGÍA Y ARQUITECTURA TECNOLÓGICA.....	8
4.1 Framework Kedro.....	8
4.2 Control de Entornos Virtuales.....	8
5. INGENIERÍA DE CARACTERÍSTICAS Y PREPROCESAMIENTO.....	9
5.1 Descripción de los Datos.....	9
5.2 El Objeto ColumnTransformer (El Corazón de la Limpieza).....	9
6. ENFOQUE 1: MODELOS DE APRENDIZAJE SUPERVISADO Y AUTOML.....	10
6.1 Random Forest (Ensamblado de Bagging).....	10
6.2 XGBoost (Extreme Gradient Boosting).....	10
6.3 Máquinas de Vectores de Soporte (SVM).....	10
6.4 Regresión Logística.....	10
6.5 K-Nearest Neighbors (KNN).....	11
6.6 TPOT (Auto-ML por Algoritmos Genéticos).....	11
7. ENFOQUE 2: MODELOS DE APRENDIZAJE NO SUPERVISADO.....	12
7.1 K-Means.....	12
7.2 DBSCAN (Density-Based Spatial Clustering of Applications with Noise).....	12
7.3 Agglomerative Clustering.....	12
7.4 Gaussian Mixture Models (GMM).....	13
7.5 Isolation Forest.....	13
8. ENFOQUE 3: AGENTES DE APRENDIZAJE POR REFUERZO (RL).....	14
8.1 Diseño de los Entornos Simulados (Gymnasium).....	14
8.2 Modelos Implementados (Librería Stable-Baselines3).....	14
9. ANÁLISIS DE RESULTADOS EXPERIMENTALES.....	15
9.1 Rendimiento en Detección de Deserción (Supervisados).....	15
9.2 Resultados de los Descubrimientos (No Supervisados).....	15
9.3 Inferencia Dinámica (Agentes RL).....	15
10. DISCUSIÓN DE RESULTADOS Y TRADE-OFFS.....	16
11. IMPLICACIONES DE NEGOCIO Y ESTRATEGIAS INSTITUCIONALES.....	17

12. LIMITACIONES DEL ESTUDIO.....	17
13. CONCLUSIONES.....	18
14. TRABAJO FUTURO Y EVOLUCIÓN DEL PRODUCTO.....	18

1. RESUMEN EJECUTIVO

El presente informe técnico de gran extensión documenta exhaustivamente el desarrollo, justificación metodológica, arquitectura y resultados de un ecosistema avanzado de Inteligencia Artificial enfocado en resolver uno de los problemas más apremiantes de la educación superior contemporánea: la deserción estudiantil y el bajo rendimiento académico.

Para abordar esta problemática multidimensional, el proyecto evolucionó desde una simple regresión logística hacia un marco de trabajo de ingeniería de software robusto apoyado en **Kedro**. Se han consolidado datos históricos de los estudiantes (calificaciones, registros de asistencia e inscripciones curriculares) para entrenar un pool masivo de **16 algoritmos de Machine Learning**.

Este arsenal analítico no se limita a un único paradigma algorítmico, sino que ataca el problema mediante una triangulación de tres enfoques distintos:

1. **Modelos Supervisados (6):** Cuya misión es clasificar predictivamente qué alumnos desertarán y proyectar sus calificaciones.
2. **Modelos No Supervisados (5):** Cuya misión es perfilar geométricamente a los estudiantes en subcomunidades (clusters) e identificar valores atípicos que el sistema académico ignora.
3. **Modelos de Aprendizaje por Refuerzo (5):** Una innovación en la prescriptiva educativa que utiliza agentes en entornos simulados para aprender a tomar secuencias de decisiones ("adivinar" e iterar) maximizando una función de recompensa basada en el éxito estudiantil.

El resultado es una plataforma de inferencia que logra identificar el riesgo antes de que se materialice, permitiendo focalizar recursos, becas y tutorías de manera inteligente.

2. INTRODUCCIÓN Y PLANTEAMIENTO DEL PROBLEMA

2.1 Contexto de la Problemática

Las instituciones de educación superior enfrentan un desafío crítico relacionado con las tasas de retención. Cuando un estudiante abandona sus estudios, la institución sufre un triple impacto:

- **Impacto Académico/Misional:** La incapacidad de la universidad para cumplir con su rol formador ante la sociedad.
- **Impacto Económico:** Pérdida de ingresos por aranceles proyectados, así como pérdida de subsidios estatales o becas ligadas a la retención.
- **Impacto Operacional:** Dificultad para planificar dotación docente y recursos de infraestructura por la volatilidad de la matrícula.

Hasta ahora, la identificación de alumnos en riesgo ha sido tradicionalmente reactiva. Los sistemas de alerta temprana convencionales suelen detonarse cuando el alumno ya ha reprobado sus asignaturas o cuando ha acumulado inasistencias severas. En esa etapa, la intervención llega demasiado tarde, resultando en altas tasas de fracaso.

2.2 Formulación del Problema Analítico

El objetivo de este proyecto es transformar los datos pasivos institucionales en una política de retención activa predictiva. Analíticamente, esto significa traducir la deserción y el rendimiento a funciones matemáticas computables:

1. **Clasificación:** Definida como $f(X) \rightarrow \{0, 1\}$, donde 0 es "Alumno Regular" y 1 es "Alumno Desertor".
2. **Regresión:** Definida como $f(X) \rightarrow \mathbb{R}$, proyectando el Promedio General Ponderado del alumno al final del ciclo.
3. **Agrupamiento:** Encontrar estructuras topológicas C_k en el espacio multidimensional X .
4. **Control Óptimo (RL):** Definir un Proceso de Decisión de Markov (MDP) donde un agente π actúa sobre el estado S_t (estudiante) para maximizar un retorno esperado G_t .

2.3 Objetivos Generales y Específicos

Objetivo General: Desarrollar un sistema de Machine Learning end-to-end reproducible, justificado teóricamente, que prevenga la deserción a través de múltiples frentes algorítmicos.

Objetivos Específicos:

- Orquestar la limpieza y preparación de datos sin riesgo de fuga (*Data Leakage*).
- Entrenar y comparar sistemáticamente algoritmos clásicos y modernos (Random Forest, SVM, XGBoost, etc.).
- Integrar herramientas AutoML para garantizar resultados que superen sesgos humanos en la creación de pipelines.
- Diseñar y probar entornos de *Gymnasium* para enseñar a modelos de Reinforcement Learning a predecir comportamiento académico.
- Modularizar el sistema completo usando la arquitectura Kedro.

3. MARCO TEÓRICO Y ESTADO DEL ARTE

El uso del Machine Learning (ML) en el ecosistema educativo (a menudo referido como *Educational Data Mining* o EDM) ha madurado significativamente. La literatura académica resalta que ninguna técnica individual soluciona todos los problemas educativos debido a la naturaleza heterogénea de los estudiantes.

3.1 Aprendizaje Supervisado en EDM

Los métodos basados en árboles, particularmente Random Forests y Gradient Boosting Machines (como XGBoost y LightGBM), son considerados el "Estado del Arte" en bases de datos tabulares (Breiman, 2001; Chen & Guestrin, 2016). Esto se debe a su naturaleza de particionamiento jerárquico, que se alinea muy bien con reglas de decisión lógicas: "Si Asistencia < 70% Y Notas < 4.0, entonces Riesgo Alto". Las máquinas de vectores de soporte (SVM) y las regresiones penalizadas ofrecen sólidas alternativas en espacios con menor dimensionalidad pero de fronteras complejas.

3.2 El Rol del Clustering Estudiantil

Autores en el campo de la analítica de aprendizaje (Learning Analytics) argumentan que "etiquetar" a los alumnos (ej. Desertor vs No Desertor) oscurece los perfiles intermedios. Los algoritmos como K-Means, DBSCAN y GMM permiten que los datos "hablen por sí solos", revelando si existen, por ejemplo, "Alumnos de alto rendimiento pero baja asistencia" frente a "Alumnos de asistencia perfecta pero bajas calificaciones".

3.3 Innovación: Aprendizaje por Refuerzo en Educación

La introducción de Agentes de Reinforcement Learning (RL) en la retención estudiantil es muy escasa y altamente innovadora. Tradicionalmente reservado para robótica y videojuegos (Sutton & Barto, 2018), el RL aquí se enfoca como una técnica de toma de decisiones secuencial. Al tratar la "predicción" como una "acción" y la "exactitud" como una "recompensa" (-1 o +1), agentes como PPO (Proximal Policy Optimization) y SAC (Soft Actor-Critic) aprenden a ajustar los pesos de sus redes neuronales mediante gradientes de políticas, ofreciendo una robustez analítica distinta a la propagación hacia atrás tradicional supervisada.

4. METODOLOGÍA Y ARQUITECTURA TECNOLÓGICA

Para escalar este proyecto de un simple script a un producto de grado industrial, se ha adoptado una metodología estricta basada en buenas prácticas de ingeniería de datos y software.

4.1 Framework Kedro

El proyecto fue construido sobre **Kedro**, un framework open-source de Python. Su uso se justifica fuertemente porque:

- **Modularidad:** Divide el análisis en "Nodos" funcionales independientes y conectables.
- **Catálogo de Datos Abstraído:** El archivo `catalog.yml` desvincula la lógica de guardado/lectura del código de modelado. Al escalar a 16 modelos, Kedro gestiona automáticamente los 16 archivos `.pkl` resultantes sin que el analista escriba una sola línea de código *Input/Output*.
- **Gestión de Dependencias (Pipelines):** Asegura el orden topológico. (Ej. Kedro sabe matemáticamente que no puede ejecutar `evaluate_rl_models_node` antes de `train_rl_models_node`).

4.2 Control de Entornos Virtuales

Un problema técnico recurrente en ciencias de datos son las discrepancias de dependencias ("*en mi computador sí funcionaba*"). El proyecto solucionó esto aislando su estado con un entorno virtual Python `.venv` vinculado rígidamente al núcleo base de Anaconda de la máquina anfitriona. Se expuso dicho entorno a Jupyter mediante el paquete `ipykernel` para que la fase experimental gráfica (Visualización) garantice la carga de modelos que fueron compilados en la consola. Esto asegura congruencia al cargar dependencias pesadas como `torch` o `stable-baselines3`.

5. INGENIERÍA DE CARACTERÍSTICAS Y PREPROCESAMIENTO

5.1 Descripción de los Datos

El modelo consume datos relacionales consolidados desde múltiples fuentes:

- **Datos Demográficos:** Sede, carrera, año de ingreso, edad inferida.
- **Rendimiento:** Promedios ponderados por semestre, cantidad de evaluaciones rendidas.
- **Comportamiento:** Asistencia general porcentual.

5.2 El Objeto ColumnTransformer (El Corazón de la Limpieza)

Un error metodológico severo en proyectos novatos es limpiar todos los datos antes de dividir entre Train y Test. Esto produce "Fuga de Datos". Para evitar esto, se justificó el uso del ColumnTransformer de Scikit-Learn:

- **Variables Numéricas:** Tienen valores atípicos severos (alumnos con 0 notas, o muy pocas evaluaciones). Se imputaron nulos con la Mediana (SimpleImputer) para evitar sesgos, y se escalaron a varianza unitaria (StandardScaler). El escalado es *condición sine qua non* para SVM, K-Means, y las redes neuronales de RL, pues evita que variables de gran magnitud (ej. Año de Ingreso vs Nota de 1.0 a 7.0) dominen matemáticamente el gradiente descendente.
- **Variables Categóricas:** La Sede y la Carrera son factores determinantes en la deserción. Se utilizó OneHotEncoder(handle_unknown='ignore'). Esto permite que si en el futuro aparece un estudiante de una "Sede Nueva", el pipeline no colapse en producción, sino que asigne vectores ceros.

Este transformador se ajusta (fit) **solo** en X_train y se congela geométricamente, exportándose como un objeto pickle a lo largo del pipeline.

6. ENFOQUE 1: MODELOS DE APRENDIZAJE SUPERVISADO Y AUTOML

El Aprendizaje Supervisado trata el problema de predecir Y a partir de X . Se implementaron 6 abordajes diferentes justificados teóricamente:

6.1 Random Forest (Ensamblado de Bagging)

Algoritmo compuesto por cientos de Árboles de Decisión entrenados sobre submuestras aleatorias (Bootstrap Aggregating).

- **Justificación Matemática:** Al promediar árboles profundos no correlacionados, reduce masivamente la varianza sin incrementar el sesgo.
- **Aplicabilidad Educativa:** Extraordinario para reglas heurísticas. Los cortes de notas y de asistencias son intrínsecamente "reglas del tipo SI/ENTONCES". Muestra cuáles variables fueron decisivas, logrando interpretabilidad para los directivos.

6.2 XGBoost (Extreme Gradient Boosting)

A diferencia de Bagging, los árboles se entrenan secuencialmente. Cada nuevo árbol modela los residuos (errores) del árbol anterior.

- **Justificación Matemática:** Optimiza funciones de pérdida diferenciables empleando regularización ($L1/L2$) intrínseca en su función objetivo.
- **Aplicabilidad Educativa:** Suele ser el ganador indiscutido en conjuntos de datos heterogéneos y fuertemente desbalanceados, ideal para identificar deserciones tempranas muy ocultas.

6.3 Máquinas de Vectores de Soporte (SVM)

Busca hiperplanos de separación que maximicen el margen geométrico entre las clases (Desertores vs Regulares).

- **Justificación Matemática:** Mediante la función *Kernel* Radial (RBF), mapea los datos a un espacio de mayor dimensionalidad donde problemas no separables linealmente se vuelven separables.
- **Aplicabilidad Educativa:** Efectivo en instituciones con cohortes pequeñas donde los límites de clasificación del éxito académico son confusos y difusos.

6.4 Regresión Logística

Modela la probabilidad de que un estudiante pertenezca a la clase de Desertores utilizando la función sigmoide.

- **Justificación Matemática:** Es un modelo aditivo generalizado (GAM) paramétrico y simple. Los coeficientes logarítmicos pueden interpretarse directamente como variaciones en las probabilidades (*Odds Ratios*).
- **Aplicabilidad Educativa:** Es el estándar de oro empírico. Funciona como modelo Base (*Baseline*). Si un algoritmo complejo no supera a la regresión logística, no justifica su complejidad en producción.

6.5 K-Nearest Neighbors (KNN)

Modelo no paramétrico basado en instancias. Clasifica a un estudiante nuevo buscando a sus "\$K\$ "vecinos" más cercanos en el espacio de características.

- **Justificación Matemática:** Minimiza distancias (Minkowski/Euclidiana) para tomar votos por mayoría.
- **Aplicabilidad Educativa:** Captura fenomenalmente la agrupación social de los estudiantes. Si 4 de 5 alumnos muy similares a "Juan" (misma comuna, mismo colegio, notas similares) desertaron, Juan tiene alto riesgo algorítmico.

6.6 TPOT (Auto-ML por Algoritmos Genéticos)

El **Tree-based Pipeline Optimization Tool** evalúa, muta y cruza pipelines completos (incluyendo selectores de features y preprocesadores) evaluando generaciones de código Python hasta hallar el óptimo global.

- **Justificación Matemática:** Elige el mejor modelo sin sesgo humano, navegando la combinatoria infinita del machine learning mediante el framework DEAP.
- **Implementación:** Se le extrae rigurosamente la `fitted_pipeline_` en nuestro nodo Kedro para remover su generador estocástico interno, volviéndolo un modelo exportable en *pickle* estándar, 100% auditable y productivizable.

7. ENFOQUE 2: MODELOS DE APRENDIZAJE NO SUPERVISADO

La institución no puede depender solo de etiquetas históricas. Estos algoritmos "descubren" los grupos sin saber quién desertó y quién no. Si dichos descubrimientos se cruzan más tarde con la etiqueta de riesgo, los insights estratégicos son masivos. Se ejecutaron 5 algoritmos de última generación:

7.1 K-Means

Algoritmo particional geométrico de asignación dura.

- **Justificación:** Busca K centroides minimizando la inercia (suma de varianzas intra-cluster). Es extremadamente rápido y funciona excelente con variables ya estandarizadas, ofreciendo promedios claros para perfiles "Bajo", "Medio" y "Alto" rendimiento.

7.2 DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

Agrupar puntos basándose en conexiones de alta densidad locales ignorando formas esféricas rígidas.

- **Justificación:** Estudiantes atípicos (aquellos con promedios excelentes pero que no asisten nunca) son detectados intrínsecamente como 'Ruido' (-1) sin afectar el cálculo de los promedios de la masa de estudiantes normales. Es más robusto que K-Means a distribuciones extrañas.

7.3 Agglomerative Clustering

Clustering jerárquico ascendente (Bottom-Up). Inicia con cada alumno siendo su propio clúster y los fusiona gradualmente mediante métricas de enlace (Linkage, p.e. Ward).

- **Justificación:** Permite construir dendrogramas. Académicamente, permite analizar macro-familias (Estudiantes Diurnos vs Vespertinos) y luego sub-dividir esas familias hasta llegar al perfil micro de cada aula.

7.4 Gaussian Mixture Models (GMM)

Enfoque estadístico generativo, asumiendo que los datos provienen de la combinación lineal de varias distribuciones normales multidimensionales.

- **Justificación:** Asignación "Suave" (*Soft Clustering*). K-Means dice: "Pedro es del Perfil A". GMM dice: "Pedro pertenece un 60% al perfil A y un 40% al perfil B". Esto es revolucionario en educación porque captura alumnos "híbridos" o en fase de transición académica.

7.5 Isolation Forest

Algoritmo basado en ensamblados de árboles para detección exclusiva de Anomalías.

- **Justificación:** En lugar de crear perfiles, Isolation Forest crea cortes aleatorios buscando "aislar" cada estudiante. Si un estudiante se aísla con muy pocos cortes, es porque está muy lejos de sus compañeros. Un estudiante aislado es a menudo un estudiante "desconectado" del sistema que requerirá atención urgente psicológica, financiera o vocacional.

8. ENFOQUE 3: AGENTES DE APRENDIZAJE POR REFUERZO (RL)

Normalmente usado en control de robots o juegos (Ajedrez, Atari), el Reinforcement Learning ha sido pioneramente adaptado aquí para la educación bajo la justificación metodológica de entrenar una red neuronal que "sobrevive" tomando decisiones asertivas.

8.1 Diseño de los Entornos Simulados (Gymnasium)

Para que el RL funcione, se construyeron dos entornos (Env) virtuales:

1. **ClassificationEnv (Discreto):** El estado (Observación) es el vector del estudiante. La Acción es "Adivinar la clase: 0 o 1". La Recompensa es +1 si acierta y -1 si falla.
2. **RegressionEnv (Continuo):** El estado es el vector. La Acción es un número flotante (Rango -100 a +100). La Recompensa es el Negativo del Error Cuadrático Medio ($-\text{MSE}$). Si el agente predice lejos de la nota real, recibe un castigo masivo; obligándolo a converger.

8.2 Modelos Implementados (Librería Stable-Baselines3)

Se entrenaron 5 algoritmos del estado del arte en RL Profundo (Deep RL):

1. **PPO (Proximal Policy Optimization):** El algoritmo "estrella" en el desarrollo de la IA moderna (usado ampliamente en la arquitectura base de ChatGPT). Optimiza un límite inferior subrogado restringido, evitando que las actualizaciones de la red neuronal destruyan políticas útiles previas. Ideal para nuestro ambiente discreto de deserción.
2. **A2C (Advantage Actor-Critic):** Arquitectura sincrónica multi-trabajador donde una red "Crítica" estima el valor del estudiante, y una red "Actriz" decide qué hacer. Altamente eficiente computacionalmente para inferencias masivas.
3. **DQN (Deep Q-Network):** Utiliza *Experience Replay* y una red objetivo separada para aproximar los valores Q . Fue la base de la revolución del RL. Justifica su inclusión como comparador clásico para el ambiente discreto.
4. **SAC (Soft Actor-Critic):** Algoritmo *Off-Policy* continuo de máxima entropía. Penaliza que el agente siempre elija la misma respuesta (buscando la exploración continua). Excelente para no colapsar la predicción de calificaciones en un simple promedio general, logrando que el agente se atreva a predecir notas extremas (ej. 7.0 o 1.0).
5. **DDPG (Deep Deterministic Policy Gradient):** Versión adaptada de Q-Learning para espacios de acción continuos con políticas deterministas. Permite ajustes precisos de inferencia de puntajes de riesgo sin oscilaciones estocásticas.

9. ANÁLISIS DE RESULTADOS EXPERIMENTALES

Las evaluaciones métricas cruzadas, almacenadas en los artefactos supervised_metrics.csv, unsupervised_metrics.csv y rl_metrics.csv, demostraron resultados coherentes y profundos.

9.1 Rendimiento en Detección de Deserción (Supervisados)

- La métrica cardinal de negocio seleccionada para la predicción de desertores es el **Recall (Sensibilidad)** combinado con el **F1-Score**. En educación, es un error fatal de diseño apostar por el *Accuracy* global frente a datos desbalanceados, ya que predecir que "nadie deserta" suele lograr más de un 80% de *Accuracy* pero un valor de negocio nulo.
- **XGBoost** y **Random Forest** dominaron sólidamente las métricas de Recall de la clase en riesgo. Su arquitectura de ensamblado pudo capturar reglas no-lineales ("si asiste poco, pero tiene excelentes notas en los semestres anteriores, todavía puede salvarse").
- La Regresión Logística y KNN mostraron buenos desempeños iniciales, pero se vieron superados en F1 general por los modelos de Ensamble y el pipeline optimizado por **TPOT**. El pipeline de TPOT, al ser validado, descubrió combinaciones complejas que la intuición humana habría tardado meses en programar a mano.

9.2 Resultados de los Descubrimientos (No Supervisados)

- **Silhouette Score**: El coeficiente de Silhouette global indicó que existe solapamiento estadístico natural. Esto confirma que los estudiantes no se dividen en burbujas absolutamente separadas, sino que existe un espectro poblacional denso.
- **Modelos de Densidad**: DBSCAN resultó ser altamente conservador. Encontró un gran "clúster principal" y catalogó a una importante masa de individuos dispersos como ruido. Curiosamente, al investigar esos puntos ruidosos (anomalías), la correlación con casos de deserción histórica futura fue altísima. **Isolation Forest** confirma esta tesis, demostrando ser el algoritmo más relevante comercialmente dentro del grupo no supervisado.

9.3 Inferencia Dinámica (Agentes RL)

- En el entorno discreto, el agente **PPO** logró maximizar su recompensa acumulada rápidamente. Al estabilizar su convergencia, la exactitud de su inferencia se igualó competitivamente con la Regresión Logística, probando la teoría de que los algoritmos de control pueden ser adaptados para tareas predictivas.
- En el entorno continuo, **SAC** fue superior a DDPG lidiando con la alta varianza del MSE al estimar las notas flotantes, reduciendo los castigos por errores drásticos en pocos centenares de episodios de interacción (*Timesteps*).

10. DISCUSIÓN DE RESULTADOS Y TRADE-OFFS

Una parte fundamental de este informe es la justificación de las concesiones y equilibrios logrados en el desarrollo del sistema de 16 modelos.

1. **Interpretabilidad vs Poder Bruto (El Trade-off de la Caja Negra):** Modelos como SAC (RL Continuo) y XGBoost logran una precisión soberbia, pero actúan como "cajas negras". Los comités académicos a menudo rechazan intervenir a un alumno si el sistema no "explica el por qué". Modelos como Random Forest o la Regresión Logística ofrecen reportes directos de "Importancia de Atributo" (Feature Importance), lo que permite que el Decano entienda qué palancas institucionales mover. Se justifica operar con ambos en paralelo.
2. **Eficiencia Computacional de Inferencia:** Mientras K-Means y LR realizan inferencias en microsegundos, los modelos de Deep RL (Redes multicasas de pytorch subyacentes) demandan mayor potencia de cómputo en CPU/GPU durante el despliegue.
3. **Gestión de Hiperparámetros (La variable de ajuste):** AutoML (TPOT) probó que una búsqueda genética con apenas una generación superó los esquemas de parámetros por defecto. Esto reafirma la premisa del proyecto de que ningún modelo puede ser implementado industrialmente sin una optimización algorítmica específica para los datos en cuestión.

11. IMPLICACIONES DE NEGOCIO Y ESTRATEGIAS INSTITUCIONALES

Este sofisticado backend predictivo no es meramente un ejercicio de computación estadística; debe enlazarse con los departamentos de Asuntos Estudiantiles para tener valor:

1. **Campañas Focalizadas de Retención (Alertas Tempranas):** Un listado extraído del modelo de Clasificación filtrado por los top percentiles de probabilidad de pertenecer a la Clase 1 (Desertores) debe ser entregado semanalmente a coordinadores de carrera para detonar entrevistas psicosociales inmediatas.
2. **Asignación de Tutorías Paritarias (Regresión):** Basándose en la predicción de rendimiento de los agentes SAC y Random Forest, la universidad puede asignar de manera preventiva apoyos extracurriculares a estudiantes cuya curva de aprendizaje proyecte reprobación crítica del semestre, antes de que rindan sus primeros certámenes.
3. **Rediseño Curricular (Clustering):** Utilizando los patrones hallados por Isolation Forest y GMM, la institución puede identificar si el currículo de ciertas carreras (evaluaciones excesivas, asignaturas cuello de botella) propicia agrupamientos tóxicos y modificar los programas de estudio macro a partir de esas señales objetivas.

12. LIMITACIONES DEL ESTUDIO

Para garantizar rigurosidad, es imperativo establecer fronteras y limitaciones en los descubrimientos actuales del proyecto:

1. **Temporalidad (Time-Series Analytics):** Actualmente el modelo procesa a los estudiantes como una fotografía "plana" (tabular agregada). La dinámica evolutiva del alumno (cómo cayeron sus notas mes a mes) no está contemplada como series temporales (LSTMs o RNNs).
2. **Desbalance Crítico Intrínseco:** En universidades consolidadas, las tasas de deserción suelen rondar el 10-20%. Esto crea un problema fundamental de sesgo muestral (*Class Imbalance*) donde algoritmos de maximización simple ignorarán a las minorías.
3. **Impacto del Factor Humano y Contextual:** Existen factores no registrados (depresión clínica, pérdida de trabajo de los tutores financieros) que ninguna técnica de RL, Supervisada o No Supervisada podrá prever si no constan en un formato de dato integrado.

13. CONCLUSIONES

1. El salto metodológico a un sistema de ensamble de **16 algoritmos de Machine Learning**, sustentado por el control de MLOps que provee **Kedro**, ha demostrado ser altamente efectivo, robusto y escalable. Se superó radicalmente el alcance limitado de un análisis univariado tradicional.
2. La combinación dual de **Aprendizaje Supervisado (Clasificación/Regresión)** con **Agrupamientos Geométricos Densos (DBSCAN / GMM / IsoForest)** y técnicas heurísticas genéticas (**TPOT**) cubre el espectro completo de inferencia, entregando una solución multi-ángulo que detecta tanto el riesgo claro como las anomalías conductuales indocumentadas.
3. La pionera integración de **Inteligencia Artificial Basada en Agentes (Reinforcement Learning)** a través de Stable-Baselines3, demuestra de forma teórica y práctica que el rendimiento educativo puede formularse como un problema de Decisión de Markov. A largo plazo, sentará las bases para que un Agente Inteligente recomiende proactivamente las mejores "acciones" (becas, correos, tutorías) de manera automática.

14. TRABAJO FUTURO Y EVOLUCIÓN DEL PRODUCTO

1. **Despliegue a Producción (CI/CD):** Integrar el backend Kedro mediante contenedores Docker a servicios en la nube (AWS SageMaker, Azure ML), conectándolo a la base de datos central de calificaciones vía SQL para ingesta diaria y re-entrenamiento automatizado mensual.
2. **Inclusión de Series Temporales y Deep Learning NLP:** Recoger textos de correos, reclamaciones de alumnos e interacción en plataformas virtuales (Moodle/Blackboard) y analizarlos usando *Large Language Models (LLMs)* locales u otras redes recurrentes para sumar una capa de análisis de sentimiento al vector de riesgo.
3. **Simulaciones Policy-Iteration de RL Completas:** Construir un Entorno Gym donde las "Acciones" del agente no sean "adivinar", sino "Ejecutar intervención". Esto convertirá a nuestro motor de Deep RL en el primer planificador autónomo de intervenciones académicas de la institución.